



Seleção de estruturas e uso de informações auxiliares no projeto de controladores baseados em dados

João Carlos Vilela de Castro

Texto de qualificação submetido à banca examinadora designada pelo Colegiado do Programa de Pós-Graduação em Engenharia Elétrica da Universidade Federal de Minas Gerais, como parte dos requisitos necessários à obtenção do grau de Mestre em Engenharia Elétrica.

Orientador: Prof. Luis Antonio Aguirre, Ph.D.

Belo Horizonte, março de 2021

Contents

Lista of Figures	v
List of Symbols	vii
List of abbreviations and acronyms	ix
1 Introduction	1
2 Basic concepts in system identification	5
2.1 Coleta e pré-processamento de dados	6
2.2 Escolha da classe do modelo	6
2.3 Seleção de estrutura	7
2.3.1 Randomized Model Structure Selection	8
2.4 Parameter Estimation	9
2.5 Model Validation	11
3 Virtual Reference Feedback Tuning	13
4 Reinforcement Learning	15
5 Controller Structure Selection	17
5.1 Methodology	18
5.2 Preliminary Results	18
6 Conclusões	23
6.1 Considerações finais	23

6.2	Propostas de continuidade	23
-----	-------------------------------------	----

List of Figures

5.1	Evolução dos RIPS para escolha dos regressores para os casos (a) 1 e (b) 2.	20
5.2	Resposta temporal a um sinal de referência a um sinal de referência (preto tracejado) na forma de degraus para o modelo de referência em (5.2) (preto contínuo) e para um possível modelo escolhido pelo algoritmo RaMSS (azul contínuo).	20

List of Symbols

Chapter 1

y_k Output signal $\in \mathbb{R}^p$, at time k ;

Chapter 2

N number of sampled data;
 \mathbf{y} vector of output data $\in \mathbb{R}^N$;

Chapter 3

Chapter 4

u_k vector input signal $\in \mathbb{R}^m$, at time k ;
 u_k vector input signal $\in \mathbb{R}^m$, at time k ;

Chapter 5

List of abbreviations and acronyms

AIC	Akaike's Information Criterion;
AICc	Corrected Akaike's Information Criterion;
ARMAX	(AutoRegressive Moving Average model with eXogenous inputs);
ARX	(AutoRegressive model with eXogenous inputs);
BIC	Bayesian Information Criterion;
ERR	Error Reduction Ratio;
MSPE	Mean Square Prediction Error;
MS1PE	Mean Square Prediction Error for one step ahead;
RaMSS	Randomized Model Structure Selection;
RIP	Regressor Inclusion Probabilitty;
FPE	Final Prediction Error;
LTI	Linear Time Invariant;
LTV	Linear Time Variant;
MA	Média Móvel (<i>Moving Average</i>);
MACSIN	Modeling, Analysis, Control and Nonlinear Systems Group; (<i>Grupo de Modelagem, Análise e Controle de Sistemas Não-Lineares</i>);
MIMO	Multiple-Input Multiple-Output;
MISO	Multiple-Input Single-Output;
NARMAX	Nonlinear AutoRegressive Moving Average model with eXogenous inputs;
NARX	Nonlinear AutoRegressive model with eXogenous inputs;
EP	Error Prediction;
PPGEE	Graduate Program in Electrical Engineering; (<i>Programa de Pós-Graduação em Engenharia Elétrica</i>);
PRBS	Sinal binário pseudo-aleatório (<i>Pseudo Random Binary Signal</i> .);
RLC	Resistivo, Indutivo e Capacitivo;
RMSE	Raiz do Erro Médio Quadrático (<i>Root Mean Error Square</i>);
SNR	Signal Noise Ratio;
SISO	Single-Input Single-Output;
IV	Instrumental Variables;
UFMG	Universidade Federal de Minas Gerais;

Introduction

The use of feedback control in mechanisms developed by humans is marked by the 1769 James Watt's invention, known as the Watt regulator and developed to regulate steam-machines spin velocities. From this time until the beginning of the 20th century, control designs were based on trial and error methods. With the emergence of theoretical publications on the subject, such as that of (Tolle, 1921), mathematical models were increasingly used in the design of controllers, mainly in the form of differential equations (Takahashi et al., 1972).

In the 30s and 50s the so-called Classical Control Theory originates, expressing itself basically in the frequency domain and in the s -plane, with models given by transfer functions, based on methods developed mainly by Nyquist, Bode, Nichols and Evans.

In the 1960s, a new control theory approach arises, using parametric models and state space representation. this approaches gives rise to the so-called Modern Control Theory and its main branches, such as systems identification, adaptive control, robust control, optimal control and stochastic control, which have been widely studied and developed until today, but still with many challenging topics, both in theoretical and practical aspects (Hou and Wang, 2013).

In both approaches, the classical control theory, mainly based on the use of transfer functions and linear systems, as in the modern control theory, mainly based on state space representations of linear and non-linear systems, a mathematical model of the process to be controlled is required*. Such model can be obtained via phenomenological modeling, or via systems identification methods. In the former case, the model is obtained using known laws from specific fields of science resulting in equations that represent it. In the latter case, using input-output data collected from the process and using systems identification techniques, models that represent the process are obtained, with a certain degree of reliability.

colocar referencia
para trabalhos rele-
vantes do tipo, para
a footnote.

Several methodologies for identifying linear and non-linear models are available in the literature (Aguirre, 2015; Ljung, 1999).

Models obtained using first principles or even by systems identification can result in high order models, with a high degree of non-linearity, which makes difficult or even impractical their use for control purposes.

Furthermore, modelling processes can be an arduous task and sometimes even

*with some exceptions like the cases where the controller is designed directly from the frequency response obtained experimentally.

colocar referencias de trabalhos aqui?

impracticable, requiring steps to validate and determine the structure of the model.

For this reason, traditional model-based control methods (MBC) are unpractical in some cases. Besides, several processes generate and store large amounts of data and the use of this data for controller design would be very convenient (Hou and Wang, 2013).

Since the input and output data of a plant contains information about its dynamics, as long as it is properly excited, it may seem unnecessary to apply the identification theory to obtain a mathematical model of the plant for controller design (Ikeda et al., 2001). Furthermore, in an attempt to obtain a model that is faithful to the behaviour of the process, a very complex model can be arrived at, and a process of order reduction may be necessary during the controller design. In this case, additional effort in identifying the model may be unnecessary when designing the controller.

In this sense, in several practical control cases in which a mathematical model describing the plant is not available, or is too complex or the uncertainty in the model is too great for the use of MBC strategies, it is very convenient to obtain the controller from measurements obtained directly from the plant.

According to Campi and Weyer (2002), this problem has attracted the attention of control engineers since the work published by Ziegler and Nichols (1942), and several extensions have been proposed since then. Such procedures, despite being similar to trial and error procedures, were widely used in the industry, perhaps due to their simplicity of design, even if at the expense of final performance losses.

Around the 1990s, new approaches to controller design without the use of models for plants began to appear in the literature, which later came to be called control based on data (DDC). Hou and Wang (2013) claim that the term *data-driven* was first proposed in computer science and only recently entered the vocabulary of the control community and, to date, there are some DDC methods known by different names, such as “*data-driven control*”, “*data-based control*”, “*modelless control*”, among others. Hou and Wang (2013) propose the following definition for DDC, based on 3 other definitions:

Definition 1.1 (Data-Driven Control). (Hou and Wang, 2013) Data-driven control includes all control theories and methods in which the controller is designed by directly using on-line or off-line I/O data of the controlled system or knowledge from the data processing but not any explicit information from mathematical model of the controlled process, and whose stability, convergence, and robustness can be guaranteed by rigorous mathematical analysis under certain reasonable assumptions.

Therefore, the DDC is different from the MBC in essence, since the controller design does not make direct or indirect use of the process model. Although at first, they look like adaptive control methods, DDC methods differ from these in that, at first, they do not need any model information, and parameter settings depend on large batches of data, instead of only a few samples of the input-output signals.

Some conceptually distinct approaches using DDC appear in the literature in the

Uma perspectiva do desenvolvimento do assunto na comunidade acadêmica pode ser obtida por uma busca pelo número de publicações na base de dados do Web of

last years, among them[†]: *Virtual Reference Feedback Tuning* (VRFT), *Iterative Feedback Tuning* (IFT), *Frequency Domain Tuning* (FDT), *Correlation Based Tuning* (CbT), originally presented by [Campi and Weyer \(2002\)](#), [Hjalmarsson et al. \(1994\)](#), [Kammer et al. \(2000\)](#) and [Karimi et al. \(2002\)](#), respectively.

Since the input and output data of a plant contains information about its dynamics, as long as it is properly excited, it may seem unnecessary to apply the identification theory to obtain a mathematical model of the plant for controller design ([Ikeda et al., 2001](#)). In addition, having obtained a model faithful to the plant, it may be necessary to reduce its order in the design of the controller. In this sense, in several practical control cases in which a mathematical model describing the plant is not available, or is too complex or the uncertainty in the model is too great for the use of MBC strategies, it is very convenient to obtain the controller from measurements obtained directly from the plant.

According to [Campi and Weyer \(2002\)](#), this problem has attracted the attention of control engineers since the work published by [Ziegler and Nichols \(1942\)](#) and several extensions have been proposed since then. However, around the 1990s, new approaches to controller design without the use of models for plants began to appear in the literature, which later came to be called control based on data (*DDC - from English, data-driven control*). [Hou and Wang \(2013\)](#) claim that the term *data-driven* was first proposed in computer science and only recently entered the vocabulary of the control community and, to date, there are some DDC methods, however they are characterized by different names, such as “*data-driven control*”, “*data-based control*”, “*modelless control*”, among others. [Hou and Wang \(2013\)](#) propose the following definition for DDC, based on 3 other definitions found on the Internet:

Definition 1.2 (Data-Driven Control). ([Hou and Wang, 2013](#)) Data-driven control includes all control theories and methods in which the controller is designed by directly using on-line or off-line I/O data of the controlled system or knowledge from the data processing but not any explicit information from mathematical model of the controlled process, and whose stability, convergence, and robustness can be guaranteed by rigorous mathematical analysis under certain reasonable assumptions.

Therefore, the DDC is different from the MBC in essence, since the controller design does not make direct or indirect use of the process model. Although at first, they look like adaptive control methods, DDC methods differ from these in that, at first, they do not need any model information, and parameter settings depend, in general, on large batches of data, instead of only a few samples of the input-output signals.

Some conceptually distinct approaches using DDC appear in the literature in the last years, among them[‡]: *Virtual Reference Feedback Tuning* (VRFT), *Iterative Feedback*

[†]it was chosen here to mention some techniques that the author found most relevant to this proposal, however others can be found in the literature ([Spall, 1992](#); [Safonov and Tsao, 1995](#); [Karimi et al., 2007](#); [Huang and Kadali, 2008](#); [Schaal and Atkeson, 1994](#); [Shi and Skelton, 2000](#))

[‡]it was chosen here to mention some techniques that the author found most relevant to this proposal,

Uma perspectiva do desenvolvimento do assunto na comunidade acadêmica pode ser obtida por uma busca pelo número de publicações na base de dados do ?, utilizando o termo “*data-driven control*” e pela combinação de termos “*data-driven* or *data-based control* or *modelless control* or *model-less control*” e seu

Tuning (IFT), *Frequency Domain Tuning* (FDT), *Correlation Based Tuning* (CbT), originally presented by [Campi and Weyer \(2002\)](#), [Hjalmarsson et al. \(1994\)](#), [Kammer et al. \(2000\)](#) and [Karimi et al. \(2002\)](#), respectively. Most of these methodologies use the concept of optimization from the minimization of a cost function, in general, measured in terms of the H_2 norm of a signal. Several DDC methods available in the literature do this optimization in an iterative way, among them, the IFT, CbT, ILC, ADP. Others do so in batches, such as the VRFT and *Noniterative data-driven model reference control* methods.

In iterative cases, the minimization of the cost function is done, typically, by gradient descent methodologies, from input-output data collected in a batch way ([Bazanella et al., 2008](#)). One drawback of these methodologies is the lack of conditions that guarantee convergence to a global minimum for the cost function in many cases. Extensions to improve the convergence properties and even reduce the number of required in-process experiments have been the subject of studies in last years ([Huusom et al., 2009](#)).

In non-iterative cases, convergence to a global minimum is generally not an issue. The VRFT method, presented by [Guardabassi and Savaresi \(2000\)](#); [Campi and Weyer \(2002\)](#) to deals with the design of SISO systems and results in a linear controller is an example. In order to solve the problem of convergence to a global minimum of a H_2 performance criterion, the VRFT focus on making the cost function be optimized sufficiently “well behaved” making optimization converge properly.

At first, given ideal conditions, convergence to the global minimum is not a problem when using the VRFT method, as it is a batch method. In addition, VRFT has no initialization problems and does not access the plant several times for experimentation, in contrast to iterative methods, allowing to maintaining the normal process operation. Extensions for non-linear controllers designs have been proposed since then ([Campi and Savaresi, 2006b](#); [Jeng and Lin, 2014, 2018](#)).

Vou terminar aqui ainda. Levar para o lado da seleção de estrutura. Se for preciso, resumo um pouco o texto anterior.

Falar um pouco, ou pelo menos citar o *Noniterative data-driven model reference control*

Basic concepts in system identification

Deixar claro na seção que a identificação não é feita somente por mínimos quadrados (é o que está parecendo). Apresentar outras abordagens. Apresentar outros tipos de modelos que não polinomiais (acho que isso é feito na seção de escolha do modelo, de maneira breve, mas não cito nada sobre estruturas, NARX, etc.) Deixar isso claro. Talvez criar uma seção para modelos NARX.

Com o objetivo de descrever fenômenos da natureza ou mesmo mecanismos e processos criados pelo próprio ser humano, foram desenvolvidos, ao longo de séculos, diversas formas de representar tais fenômenos por meio de expressões matemáticas, conhecidas como modelos matemáticos, ou simplesmente, modelos.

Para obtenção de tais modelos, de maneira geral, duas abordagens podem ser utilizadas: modelagem pelos primeiros princípios, ou modelagem por identificação de sistemas. No primeiro caso, os modelos são obtidos a partir de aplicações de leis, em geral da física, desenvolvidas e documentadas ao longo dos anos de observações de fenômenos, naturais ou não, por cientistas das mais diversas áreas. No segundo caso, modelos matemáticos são obtidos a partir de análises feitas em dados de sinais colhidos do sistema a modelar valendo-se de técnicas de identificação desenvolvidas para tal. Em ambos os casos os modelos obtidos são expressões matemáticas que descrevem o comportamento aproximado do processo modelado.

No presente trabalho, não é de interesse a obtenção de um modelo para o processo e sim de um modelo para o controlador. No entanto, as metodologias utilizadas para identificação de sistemas podem ser usadas diretamente, ou em alguns casos, com adaptações específicas para fins de identificação de controladores. Neste sentido, técnicas de identificação utilizadas no âmbito de identificação de modelos têm sido usadas no projeto de controladores orientados a dados, visando tanto modelos de controladores lineares ([Campi and Weyer, 2002](#)) quanto não lineares ([Campi and Savaresi, 2006a](#)).

Com o passar dos anos, com o aumento do poder de processamento dos computadores assim como facilidade na aquisição e armazenamento de dados, o uso de técnicas de identificação de modelos não lineares vêm cada vez mais se mostrando interessantes para previsões ou até mesmo para melhor entendimento de fenômenos. Da mesma forma, espera-se que controladores não lineares projetados por técnicas de controle orientado a dados resulte muitas vezes em controladores com melhor desempenho ou até mesmo maior robustez.

Nas últimas décadas, vários trabalhos dedicados a modelagem de sistemas não lineares têm sido publicados ([Aguirre et al., 2000](#); [Aguirre and Billings, 1995](#); [Billings,](#)

1980; Billings et al., 1989; Chen et al., 1990; Chen and Billings, 1992; Korenberg et al., 1988; Leontaritis and Billings, 1985a,b; Zhu, 2005). O processo de identificação de sistemas consiste basicamente nos seguintes passos: (1) Coleta de dados; (2) Escolha do tipo de modelo; (3) Seleção de estrutura; (4) Estimação de parâmetros; (5) validação do modelo. As próximas seções tratam de maneira breve cada um desses passos.

2.1 Coleta e pré-processamento de dados

O primeiro passo na identificação (de modelos) de sistemas é a coleta de dados. Neste processo alguns cuidados devem ser tomados quanto ao intervalo de amostragem considerado ao se colher sinais, geralmente de saída, do sistema a se identificar. Para sistemas não autônomos, caso dos sistemas controlados, deve-se ainda tomar certos cuidados na escolha do sinal utilizado para excitação do processo, quando possível.

Os sinais de entrada devem ser projetados de maneira a excitar a dinâmica do sistema na faixa de frequências de interesse, por meio da escolha de sinais com potências espectrais adequadas. Neste caso é dito que o sinal deve ser *persistentemente excitante*. Sinais como ruído branco filtrado ou sinais binários pseudo-aleatórios (PRBS) são comumente utilizados na prática.

A escolha adequada da amplitude do sinal de entrada também é um fator que merece cautela. Por exemplo, o sinal não deve ser tal que leve a resposta do processo a ultrapassar certos limiares, próximos a um ponto de operação, que garantem um comportamento próximo ao linear para o caso da identificação de modelos lineares. Da mesma forma, quando a identificação é de um modelo não linear, a amplitude deve ser tal que explore as características não lineares do processo. Problemas como superamostragem, outliers, ou casos em que os sinais de excitação não podem ser previamente escolhidos, podem ser resolvidos ou amenizados por tratamento prévio dos dados, processo conhecido como pré-processamento.

2.2 Escolha da classe do modelo

Existem diversas classes modelos que podem ser utilizados para descrever a relação entrada-saída de um processo. Estas classes apresentam diferentes estruturas que se mostram mais ou menos adequadas a determinada aplicação. Por exemplo, para sistemas não lineares, a estrutura do modelo deve se mostrar complexa o suficiente para representar as não linearidades de interesse. Dentre as diversas classes usuais na representação de modelos destacam-se: funções radiais de base (Broomhead and Lowe, 1988), redes neurais (Haykin, 1994), wavelets (Strang, 1989), séries de Volterra (Billings, 1980), funções polinomiais e racionais (Billings et al., 1989).

2.3 Seleção de estrutura

Uma vez definida a classe de um modelo, a escolha de sua estrutura (i.e., número e/ou ordem de termos em um modelo polinomial NARX) passa a ser a próxima tarefa, antes da identificação de seus parâmetros. Esta pode ser uma tarefa difícil, uma vez que deseja-se encontrar um modelo com variância e polarização (viés) menores possíveis, e estas duas grandezas se mostram contraditórias. Em suma, o modelo deve ser suficientemente rico para capturar a dinâmica e repetir o comportamento do sistema modelado, mas não tanto ao ponto de modelar os ruídos presentes nos sinais amostrados. Se o modelo é muito simples, pode não se ajustar bem aos dados de treinamento, e se complexo demais (com muitos termos), pode afetar a predição do comportamento para dados diferentes daqueles usados no treinamento.

Encontrar palavra melhor que *contraditórias*.

Na tentativa de achar uma solução para esse problema, abordagens tem sido apresentadas nas últimas décadas. Dentre elas destaca o Akaike's Information Criterion (AIC), assim como sua versão corrigida, (AICc). O AIC, introduzido por Akaike (1974), é definido como:

$$AIC(n_\theta) = N \ln[\sigma_{\text{erro}}^2(n_\theta)] + 2n_\theta, \quad (2.1)$$

sendo N o número de dados, $\sigma_{\text{erro}}^2(n_\theta)$ a variância dos resíduos e $n_\theta = \dim[\hat{\theta}]$ o número de parâmetros do modelo. Segundo Aguirre (2015), (2.1) pode ser analisada pelo seguinte: “À medida que termos são incluídos no modelo, o número de grau de liberdade aumenta, permitindo um ajuste aos dados mais exato. Assim, $\sigma_{\text{erro}}^2(n_\theta)$ diminui a medida em que aumenta”. Mas “... a partir de determinado momento, a diminuição na variância dos resíduos resultante da inclusão de um novo termo é insignificante e não justificaria a inclusão do respectivo termo”. Em suma, a primeira parcela de (2.1) quantifica a diminuição na variância dos resíduos devido à inclusão de um termo, ao passo que a segunda parcela penaliza a inclusão de cada termo.

Visando corrigir um problema apresentados pelo AIC que eleva a probabilidade do AIC a selecionar modelos com alto número de parâmetros quando o tamanho da amostra é pequeno, o que leva a um sobre-ajuste, surge o AICc (Cavanaugh, 1997), dado pela equação

$$AICc = AIC + \frac{2k^2 + 2k}{n - k - 1}. \quad (2.2)$$

falar um pouquinho mais sobre este caso.

Outros critérios parecidos com de Akaike também podem ser encontrados na literatura, dentre eles, o Bayesian Information Criterion (BIC), (Schwarz, 1978); e o Final Prediction Error (FPE) (Kashyap, 1977).

Outras abordagens, já consideradas clássicas, que diferem dos critérios anteriormente citados podem ser encontradas na literatura, com destaque para a Error Reduction Ratio (ERR) (Billings et al., 1989). Nesta abordagem, a redução da variância dos ruídos que ocorre quando um novo termo é incluído no modelo é quantificada e normalizada com respeito à variância de saída. A ERR resultante da inclusão do i -ésimo

regressor é dada por

$$[ERR]_i = \frac{MS1PE(v_{i-1}) - MS1PE(v_i)}{\langle \mathbf{y}, \mathbf{y} \rangle}, \quad (2.3)$$

sendo $i = 1, 2, \dots, m$; m o número de termos candidatos testados; $MS1PE v_i$ o erro de um passo a frente do modelo com i termos, ou regressores; e v representa uma família de modelos com estruturas aninhadas tal que $v_{i-1} \subset v_i$.

Extensões do critério ERR são possíveis, como o ERR_2 (Alves et al., 2012), que usa predição 2 passos a frente ao invés de 1. Outro critério parecido com a ERR é a Simulation Error Reduction Ratio (SRR), introduzida por (Piroddi and Spinelli, 2003), e que se mostra vantajosa em condições não ideais, resultando muitas vezes em modelos mais compactos, mas com custos computacionais mais elevados. Ela é dada por

$$[SRR]_i = \frac{MSSE(v_{i-1}) - MSSE(v_i)}{\langle \mathbf{y}, \mathbf{y} \rangle}, \quad (2.4)$$

onde agora $MSSE v_i$ representa o erro médio quadrático de simulação para o modelo com i regressores, o que implica no uso de simulação livre.

Técnicas mais recentes, muitas das quais se baseiam em abordagens do tipo Monte Carlo, têm sido apresentadas à comunidade acadêmica nos últimos anos. Para fins desta pesquisa, destaca-se o método Randomized Model Structure Selection, ou simplesmente, RaMSS (Falsone et al., 2014, 2015).

2.3.1 Randomized Model Structure Selection

Coloquei o RaMSS por enquanto nesta seção, mas estou querendo colocar em um capítulo a parte. Só mencioná-lo na seção anterior como método de seleção de estrutura. No capítulo a parte colocarei uma introdução sobre métodos estatísticos e teria ainda espaço para exemplos de aplicação do RaMSS para identificação de sistemas (processos). Mai a frente abordaria o uso para identificação de controladores.

O método RaMSS, apresenta uma abordagem aleatorizada para escolha de uma estrutura de modelo adequada por meio da amostragem de modelos de um conjunto de modelos \mathcal{M} . Introduzido por Falsone et al. (2014) e aperfeiçoado em (Falsone et al., 2015), o método realiza a tarefa de seleção de estrutura de maneira probabilística que, apesar do caráter aleatório, evita a busca exaustiva necessária para analisar todos os regressores do conjunto de regressores candidatos, definido por \mathcal{R} , que seria necessário ao se utilizar força bruta em uma estratégia puramente Monte Carlo.

O método procura iterativamente pelo melhor subconjunto de regressores no conjunto \mathcal{R} visando maximizar a acurácia da predição do modelo. Isto é feito através de modelos candidatos, subconjuntos de \mathcal{M} , construídos a partir de regressores amostrados do conjunto \mathcal{R} com a probabilidade de escolha dada por uma função de probabilidade estimada chamada de RIP (Regressor Inclusion Probability). Uma vez escolhido o modelo candidato, este é avaliado de acordo com algum critério de desempenho e os RIP são atualizados. A cada iteração, N_p modelos são tomados de \mathcal{M} e índices de desempenho são calculados para a atualização dos RIP. Estes índices em geral são

parece que faltou falar de \mathbf{y} .

tentar colocar isso (a definição do conjunto) de uma maneira mais formal (fórmula).

passar para PT/EN

baseados no MSPE, MSSE ou uma combinação dos dois. e são usados para calcular um índice médio de desempenho do regressor, Assumindo um conjunto de N_p modelos em que alguns contêm o j -ésimo regressor, um índice que mensura o *desempenho médio do regressor*, que pode ser usado no cálculo do RIP é definido como

$$\mathcal{I}_j^+ = \frac{1}{n_j^+} \sum_{i=1}^{n_j^+} \mathcal{J}_i^+ \quad (2.5)$$

onde n_j^+ é o número de modelos extraídos e \mathcal{J}_i^+ é um vetor e índices de desempenho, ambos para os modelos que contêm o j -ésimo regressor.

A cada iteração os RIPs são atualizados de acordo com um processo de Bernoulli, sendo o RIP a variável aleatória de Bernoulli com probabilidade de sucesso μ_j . Depois de algumas simulações é esperado que os desempenhos médios dos modelos que contêm os regressores certos fiquem significativamente maiores que os que não contêm, fazendo com que os regressores “corretos” sejam mais prováveis de serem incluídos no modelo final.

2.4 Parameter Estimation

No processo de identificação de sistemas dinâmicos, uma vez que os dados são colhidos, pré-processados e a classe do modelo e sua estrutura são escolhidos, o problema passa ser o de se determinar os melhores parâmetros para este modelo. A este processo dá-se o nome de estimação de parâmetros. O objetivo é encontrar uma função paramétrica $\hat{f}(\varphi_{k-1}, \hat{\theta}) : \mathbb{R}^{n_\theta} \mapsto \mathbb{R}$ que se aproxime da função ideal e em geral, desconhecida, $f(\varphi_{k-1}) : \mathbb{R}^{n_\theta} \mapsto \mathbb{R}$ por meios de dados de treinamento amostrados. Desta forma

$$y_k = f(\varphi_{k-1}) \approx \hat{f}(\varphi_{k-1}, \hat{\theta}), \quad (2.6)$$

em que $\varphi_{k-1} \in \mathbb{R}^n$ é o vetor de regressores, formados por combinações lineares ou não lineares da saída $y_{k-1}, \dots, y_{k-n_y}$ e/ou entrada $u_{k-1}, \dots, u_{k-n_u}$ representa um vetor de regressores; $\hat{\theta} \in \mathbb{R}^n$, um vetor de parâmetros estimados; $y_k \in \mathbb{R}$, o sinal amostrado no instante k ; e n_θ, n_y, n_u representam respectivamente: o número de parâmetros e os máximos atrasos na saída e na entrada.

Considerando que a função ideal $f(\varphi_{k-1})$ possa ser escrita na forma paramétrica

$$y_k = f(\varphi_{k-1}, \theta), \quad (2.7)$$

em que $\theta \in \mathbb{R}^n$ é o vetor de parâmetros ideal, esta função define um conjunto de equações, ou restrições, que pode ser reescrita, para várias observações do escalar y , da

Aqui está parecendo que a estimação é feita exclusivamente por mínimos quadrados. Deixar claro que não. Citar outras. Criar uma seção para mínimos quadrados.

seguinte forma:

$$\begin{aligned} y_k &= f(\varphi_{k-1}, \theta) \\ y_{k-1} &= f(\varphi_{k-2}, \theta) \\ &\vdots \\ y_{k+1-N} &= f(\varphi_{k-N}, \theta), \end{aligned} \quad (2.8)$$

sendo y_k a k -ésima observação de y , e $\varphi_{k-1} = [\varphi_{k-1,k} \ \varphi_{k-2,k} \ \dots \ \varphi_{k-n_\theta,k}]^T$ a k -ésima observação dos n_θ regressores no instante, ou amostra, k .

Assumindo que f é linear nos parâmetros θ e que tanto f quanto θ não mudam de uma restrição para a outra em (2.8), pode-se escrever (2.7) na seguinte forma matricial

$$\mathbf{y} = \Psi \theta, \quad (2.9)$$

em que $\Psi = [\varphi_{k-1}^T \ \varphi_{k-2}^T \ \dots \ \varphi_{k-N}^T]$ e $\mathbf{y} = [y_k \ y_{k-1} \ \dots \ y_{k+1-N}]^T$.

Se $N = n_\theta$ restrições, o vetor de parâmetros θ pode ser determinado por

$$\theta = \Psi^{-1} \mathbf{y}. \quad (2.10)$$

Porém se $N > n_\theta$ restrições são tomadas, o sistema é dito sobre-determinado e a matrix X passa a ser não quadrada e não invertível. Uma solução é reescrever (2.9) de forma que a solução não seja exata, a partir da introdução de um termo de erro $\xi \in \mathbb{R}^N$, conhecido como vetor de *resíduos*, resultando em

$$\mathbf{y} = \Psi \hat{\theta} + \xi. \quad (2.11)$$

Para que o modelo capture o comportamento do processo modelado, é intuitivo que o vetor de parâmetros estimados $\hat{\theta}$ seja escolhido de forma que ξ seja reduzido em algum sentido. Na estratégia conhecida como Mínimos Quadrados Ordinário ou, simplesmente, mínimos quadrados ou LS (do inglês Least Squares), uma função de custo relacionada ao vetor de resíduos é definida como

$$J_{LS} = \sum_{k=1}^N \xi(k)^2 = \xi^T \xi = \|\xi\|^2. \quad (2.12)$$

Prova-se que o vetor $\hat{\theta}_{LS}$, definido como o conjunto de parâmetros que minimiza J_{LS} pode ser calculado por meio da pseudo-inversa de Ψ , de forma que (Aguirre, 2015):

$$\hat{\theta}_{LS} = [\Psi^T \Psi]^{-1} \Psi^T \mathbf{y}. \quad (2.13)$$

A equação (2.13) representa o estimador dos mínimos quadrados, onde os parâmetros são determinados pela minimização da função de custo referente ao somatório do

quadrado dos erros de modelagem. Alternativas numéricas mais interessantes que o algoritmo clássico de (2.13) podem ser encontradas (Aguirre, 2015; Ljung, 1999), porém o fundamento básico permanece o mesmo.

2.5 Model Validation

Tendo-se estimado os parâmetros que minimizam o resíduo em algum sentido, como por exemplo em função do somatório do quadrado dos erros de modelagem, caso dos mínimos quadrados apresentado em (2.13), deve-se avaliar o desempenho do modelo quando este estiver sujeito a excitações diferentes daquelas submetidas durante o processo de identificação (treinamento).

Para isso, é comum utilizar-se de um conjunto de dados amostrados diferente daquele usado no processo de identificação. A este conjunto de dados dá-se o nome de conjunto de validação. É usual colher-se uma certa quantidade de dados do processo, sujeito a um sinal de excitação adequado, e posteriormente dividir o conjunto de dados resultante em um conjunto de treinamento e outro de validação.

O passo seguinte consiste em utilizar-se de algum índice de desempenho de forma a quantificar a qualidade da previsão em um teste conhecido como *free-run simulation*. Nessa simulação, o modelo obtido no processo de identificação é submetido ao mesmo sinal de excitação sob o qual fora submetido o conjunto de validação. Os resultados simulados e colhidos armazenados previamente são então comparados a partir de alguma métrica. Dentre as métricas mais usuais, destacam-se o *Mean Square Error* (MSE) e a *Mean Absolute Percentage Error* (MAPE).

O MSE é dado por

$$MSE = \frac{1}{N} \sum_{k=1}^N (y_k - \hat{y}_k)^2, \quad (2.14)$$

sendo M o número de amostras, y_k o dado amostrado no intervalo k e \hat{y}_k a predição do modelo. O MSE pode ser calculado tanto sobre os dados de treinamento quanto sobre dados de validação. Porém, para fins de validação, os dados de validação devem ser utilizados, uma vez que assim pode-se obter uma medida do desempenho para o modelo se comportando fora do ambiente de treinamento. Um bom modelo, em geral, deve apresentar o MSE sobre os dados de validação próximo ao MSE sobre os dados de treinamento.

O MAPE, por sua vez, calcula o desvio absoluto da predição em relação aos dados observados e é, em geral, calculado em porcentagem, na forma

$$MAPE = \frac{100\%}{N} \sum_{k=1}^N \frac{|y_k - \hat{y}_k|}{|\max(y_k) - \min(y_k)|}. \quad (2.15)$$

Diferentes formas de escolha dos dados de treinamento e validação diferente da

usual apresentada em (2.15) podem ser usados. Uma destas formas é a “leave-one-out cross-validation”, em que apenas um dado, de todo o conjunto de dados é usado de cada vez (Allen, 1974).

Além da validação quantitativa em geral recorre-se ainda a uma avaliação qualitativa, na qual é realizada uma comparação gráfica, quanto ao comportamento dinâmico, entre a curva do sinal amostrado e a curva do sinal estimado pelo modelo resultante.

Melhorar este final

Virtual Reference Feedback Tuning

The *Virtual Reference Feedback Tunning* method, or simply VRFT, proposed by [Campi et al. \(2002\)](#), is a procedure that aims to design closed loop controllers based only on data sampled from the process, without the need for a model that describes that process itself. Thus, it is classified as a data-based control method or DDC.

The main objective of this method is to adjust the parameters of a controller, defined by a parametric function, using the process sampled data only, so that the output signal of the controlled process behaves as close as possible to the output signal of a previously defined reference model. To reach this objective, VRFT aims to optimize the tracking error by minimizing a performance index $J_y(\theta)$, defined by

$$J_y(\theta) \triangleq \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N [y_r(k, \theta) - y_{MR}(k)]^2, \quad (3.1)$$

where N represents the number of data samples, $\theta = [\theta_1 \ \theta_2 \ \cdots \ \theta_N]^T \in \mathbb{R}^n$ a vector of parameters, k a temporal index. The signals $y_r(k, \theta) \in \mathbb{R}$ and $y_{MR}(k) \in \mathbb{R}$ are defined as follows:

- $y_r(k, \theta)$ representa a resposta obtida em malha fechada quando sobre o efeito de um sinal de referência $r(k)$, ou seja

$$y_r(k, \theta) \triangleq T(q, \theta)r(k), \quad (3.2)$$

onde $T(q, \theta)$ representa o modelo em malha fechada, função do vetor de parâmetros θ e q um operador de deslocamento temporal.

- $y_{MR}(k)$ representa a resposta temporal obtida ao se aplicar o sinal de referência $r(k)$ como sinal de entrada de um modelo $T_{MR}(q)$, conhecido como *modelo de referência* e que representa o comportamento desejado em malha fechada, ou seja

$$y_{MR}(k) \triangleq T_{MR}(q)r(k), \quad (3.3)$$

Para alcançar o objetivo de minimizar (3.1), [Campi et al. \(2002\)](#), para o caso linear, e [Campi and Savaresi \(2006a\)](#), para o caso não linear, mostram que, sob certas condições,

apresentadas na sequência, ao se minimizar um índice de custo definido como

$$J_{VR}(\theta) \triangleq \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{k=1}^N [u(k) - C(q, \theta)e(k)]^2, \quad (3.4)$$

minimiza-se também o índice $J_y(\theta)$ definido em (3.1). Em (3.4), $u(k)$ representa o sinal de entrada aplicado ao processo durante a coleta de dados, $C(q, \theta)$ o modelo do controlador a ser ajustado e $e(k)$ é o chamado *erro virtual*, definido como

$$\bar{e}(k) = \bar{r}(k) - y(k), \quad (3.5)$$

onde \bar{r} é o sinal de *referência virtual*, obtido ao se filtrar a saída $y(k)$ pelo modelo de referência inverso, na forma

$$\bar{r}(k) = T_{MR}^{-1}(q)y(k). \quad (3.6)$$

O termo “virtual” é adotado em referência (ou erro) virtual para enfatizar que nenhum destes sinais são fisicamente disponíveis, mas apenas calculados para fins de projeto do controlador.

Como mencionado anteriormente, para que $J_y(\theta)$ e $J_{VR}(\theta)$ apresentem seus valores mínimos para a mesma solução de parâmetros θ , certas condições devem ser satisfeitas. Estas condições são apresentadas na sequência, logo após algumas definições que se mostram importantes para o restante do capítulo.

Definition 3.1 (Ideal Controller).

Put definition here.

Assumption 3.1 (Noise free). The system is not affected by noise.

Assumption 3.2 (Matched control). The ideal controller belongs to control model class considered, i.e. $C_d(q) \in \mathcal{C}$, or, equivalently

$$\exists \theta_d : C(q, \theta_d) = C_d(q). \quad (3.7)$$

melhorar isso aqui.

Reinforcement Learning

Aqui vai o capítulo de RL.

To LAA: Preferi não colocar o capítulo de RL aqui para não dar volume à toa. Por enquanto ele está basicamente igual a aquele que lhe entreguei no semestre passado. O texto final será uma versão mais enxuta e concisa (o atual está dando umas 25 páginas e está confuso). Mas estou planejando fazer essa parte por último.

Controller Structure Selection

Neste capítulo, são apresentadas propostas para projeto de controladores DDC no que diz respeito à escolha de estrutura do controlador. A metodologia utilizada, assim como os resultados Preliminares obtidos em uma primeira etapa de testes são apresentados.

Nesta pesquisa, o foco tem sido dado ao estudo e desenvolvimento de técnicas de seleção de estruturas para o modelo de controladores realimentados em procedimento de projeto DDC. A intenção é, no âmbito de controle de sistemas não lineares, adaptar técnicas de seleção de estruturas conhecidas na área de identificação de sistemas para lidar com o caso de controle, onde neste caso, o sistema a ser identificado, passa a ser o controlador. Para atingir estes objetivos optou-se pelo uso de modelos polinomiais para representação dos controladores, inicialmente com estruturas NARX. Esta escolha é conveniente devido à característica de flexibilidade estrutural e a capacidade desses modelos em descrever sistemas não lineares (Pearson, 1999; Martins et al., 2013).

Como mencionado no Capítulo 2, uma das principais etapas no procedimento de identificação de sistemas a partir de dados é a etapa de escolha do modelo. Trabalhos que visam dar uma luz a esta tarefa têm sido propostos, como o caso dos trabalhos desenvolvidos por Falsone et al. (2014, 2015) em que uma abordagem aleatória é utilizada a fim de selecionar os melhores candidatos entre os possíveis regressores na formação do modelo a ser identificado.

Mais recentemente, Retes and Aguirre (2019) estenderam a estratégia RaMSS para escolha de estruturas de modelos NARMAX, que levam em conta o efeito de ruídos nos sinais no intuito de reduzir a polarização nas estimativas paramétricas.

No âmbito de projeto de controladores baseado em dados, mais especificamente pelo método VRFT, em que os parâmetros do controlador são ajustados por técnicas de identificação convencionais como OLS, ILS, IV, dentre outras, o mesmo problema de escolha de estrutura do modelo ocorre, com a diferença que agora o modelo representa o controlador, e não mais o processo. Portanto, analogias devem poder serem feitas em relação ao uso do método RaMSS no intuito de estendê-lo para fins de identificação da estrutura mais adequada para o controlador.

Neste sentido, o presente trabalho tem se voltado a estudar possibilidades e consequências do uso dessas tecnologias para escolha da estrutura do controlador que se mostre mais adequada para fins de controle. Como metodologia para atingir este objetivo, listam-se as etapas a seguir, que por sua vez são detalhadas nas seções subse-

Colocar aqui mais referências neste sentido. Seleção de estruturas.

quentes:

- O método RaMSS, como concebido originalmente, é implementado em ambiente computacional e a partir de simulações de processos deseja-se certificar de que a metodologia apresenta bons resultados para identificação de processos, além de garantir que algoritmo esteja funcionando de acordo com o esperado. Alguns resultados são brevemente analisados.
- O algoritmo utilizado na etapa anterior é usado, na sequência, para primeiros testes de projeto de controladores a partir da estratégia VRFT sem modificações significativas em seu mecanismo. Neste cenário se espera alguns primeiros resultados, mas sem maiores compromissos com resultados satisfatórios, mas de grande valia para análise e comparação das modificações propostas. Respostas para sistemas previamente definidos são analisados.
- Como passo seguinte, modifica-se o cálculo do índice de custo responsável pelo cálculo dos RIP do algoritmo RaMMS, visando adaptar estes índices para fins de controle.
- Na sequência apresenta-se um estudo a respeito do uso de informações auxiliares durante o projeto do controlador, como introdução de restrições durante a etapa de identificação que garantam características desejáveis e previamente definidas na malha fechada.

Por fim, discussões a respeito de estabilidade, convergência, polarização e robustez são apresentadas, ainda não em um contexto de garantias, mas como conjecturas de passos que pretende-se aprofundar na sequência da presente pesquisa.

5.1 Methodology

5.2 Preliminary Results

Example 5.2.1 (Sistema linear de 2a ordem). Considere o seguinte sistema linear de segunda ordem no tempo discreto:

$$y_k = a_1 y_{k-1} + a_2 y_{k-2} + b_1 u_{k-1} + b_2 u_{k-2}, \quad (5.1)$$

onde, para $i = 1, 2$, os termos $a_i, b_i \in \mathbb{R}$, representam parâmetros constantes; $u_{k-i} \in \mathbb{R}$ e $y_{k-i} \in \mathbb{R}$, os sinais de entrada e saída, respectivamente; e k o índice temporal. De acordo com a estratégia VRFT (Capítulo 3), deve-se primeiramente definir uma classe de controladores admissíveis \mathcal{C} , contendo a estrutura do controlador desejado, e definir um modelo de referência que expresse o comportamento do sistema em malha fechada desejado.

A fim de se examinar o comportamento do Algoritmo RaMSS em achar o melhor conjunto de parâmetros, procede-se da seguinte maneira:

Define-se um modelo de referência factível, ou seja com grau relativo igual ou superior ao do processo. Por simplicidade, escolhe-se um modelo de 1a ordem com mesmo grau relativo, dado pela função de transferência

não estou certo se posso usar esta palavra "factível".

$$T_d(z) = \frac{1 - A}{1 - A^2}, \quad (5.2)$$

sendo A um parâmetro de projeto relacionado a constante de tempo do sistema por $A = \frac{T_s}{\tau_d}$, sendo T_s o período de amostragem e τ_d a constante de tempo desejada.

Como nesse exemplo teórico o modelo do processo é completamente conhecido, o controlador compatível (ideal), pode ser calculado facilmente por ??, o que resulta, no domínio temporal, na seguinte equação de diferenças

$$m_k = \theta_0 e_k + \theta_1 e_{k-1} + \theta_2 e_{k-2} + \theta_3 m_{k-1} + \theta_4 m_{k-2}, \quad (5.3)$$

em que $m_k \in \mathbb{R}$ e $e_k \in \mathbb{R}$ representam respectivamente os sinais de controle e erro de rastreamento no instante k , e θ_i , com $i = 1, 2, 3, 4$, os parâmetros do controlador. Adotando, $a_1 = a_2 = b_1 = b_2 = A = \tau_d = T_s = 1$, como parâmetros para os modelos de processo e de referência, e através de (??) e (5.3) chega-se ao vetor de parâmetros θ para o controlador ideal, definido como

$$\theta^T = [\theta_0 \ \theta_1 \ \theta_2 \ \theta_3 \ \theta_4]^T = [10.38 \ -16.66 \ 6.957 \ 0.125 \ 0.875]^T \quad (5.4)$$

Utilizando o algoritmo RaMSS, como abordado na seção 2.3.1. O procedimento é executado para 2 casos:

caso 1 o conjunto universo \mathcal{M} é tomado como todos os possíveis modelos lineares formados pelos regressores com até 4 e 6 atrasos temporais para o sinal de entrada (erro virtual, \bar{e}_k) e saída (sinal de excitação do processo, u_k), respectivamente. Os parâmetros de simulação apresentados na tabela 5.1. (caso

caso 2 o conjunto universo \mathcal{M} é tomado como todos os possíveis modelos *não lineares* formados pelos mesmos regressores do caso anterior.

Os parâmetros de simulação para os 2 casos são apresentados na tabela 5.1.

Table 5.1: Parâmetros para simulação do algoritmo RaMSS do exemplo 5.2.1

Caso	o	n_e	n_m	N_p	N_i	K_J	γ
1	1	7	4	100	100	1	0.1
2	2	7	4	100	100	1	0.1

Os seguintes controladores são encontrados para o casos 1 e 2,

Estou pensando em colocar a tabela em apêndice, com significado dos símbolos apresentados por lá.

$$\begin{aligned}
m_1(k) &= 10.0707145e_1(k) - 16.2413162e_1(k-1) + 6.8274122e_3(k-1) \\
&\quad + 0.1941415m_1(k-1) + 0.8059737m_1(k-2), \\
m_2(k) &= 3.4128550e_2(k) - 3.2267597e_2(k-1) + 0.5117530m_2(k-1) + 0.4807692m_2(k-2),
\end{aligned}$$

onde o índice nas variáveis representam os respectivos casos.

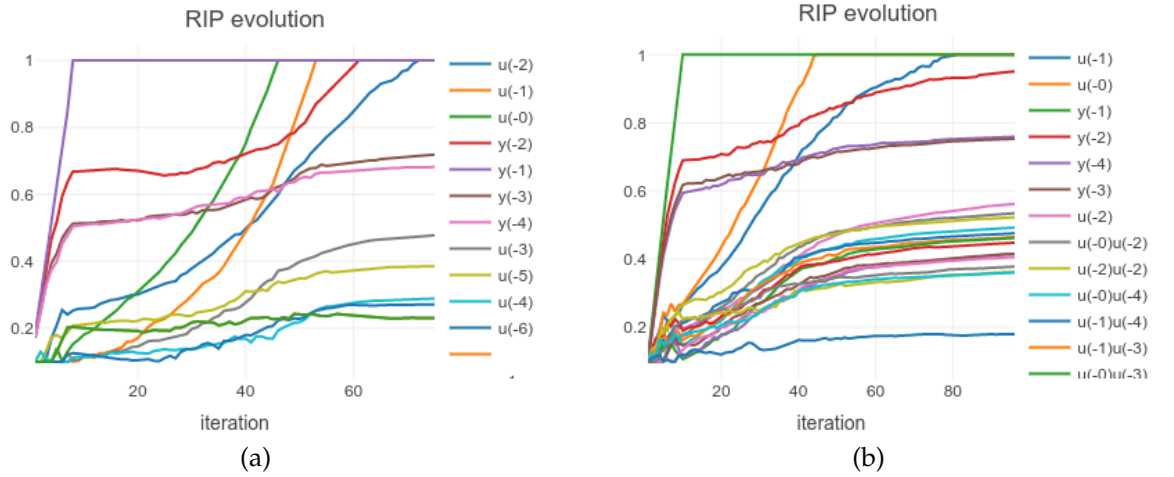


Figure 5.1: Evolução dos RIPs para escolha dos regressores para os casos (a) 1 e (b) 2.

A figura 5.2 mostra a resposta temporal para os 2 casos.




Figure 5.2: Resposta temporal a um sinal de referência a um sinal de referência (preto tracejado) na forma de degraus para o modelo de referência em (5.2) (preto contínuo) e para um possível modelo escolhido pelo algoritmo RaMSS (azul contínuo).

To LAA: Aguirre, peço desculpas pelas figuras ainda com legendas e com qualidades não vetoriais. Ainda não pesquisei um método efetivo para produzir figuras melhores. Uma alternativa fácil para mim é plotar pelo Matlab. Mas creio que pelo R será tranquilo também. Mas só devo ajustar as figuras lá para o final de semana.

Nota-se que ao se considerar somente termos lineares como candidatos, o algoritmo converge para o conjunto de regressores do caso ideal, porém o mesmo não ocorre quando se considera o caso com termos não-lineares. Mesmo ao repetir o procedimento de forma aleatória e exaustiva, o resultado permanece parecido, convergência para a estrutura ideal para o caso 1 e praticamente todos os casos e convergência para diferentes estruturas, que muitas vezes não condiz com o caso ideal.

Este exemplo serve como base para mostrar o comportamento do RAmSS quando utilizado diretamente ao projeto VRFT. Porém nenhuma adaptação é feita a fim de lidar com seleção de estruturas de controlador especificamente.

To LAA: O exemplo anterior está mal terminado. Estava trabalhando nele agora por último. Mas estou cansado e estou vendo que piorando mais do que melhorando. Então estou enviando o arquivo do jeito que está.

To LAA: Quis fazer um exemplo simples para começar, acabou me tomando mais tempo do que deveria. A ideia seria apresentar alguns exemplos (ao longo de uma metodologia que ainda está faltando), primeiramente este, que mostra a aplicação direta do RAmSS ao problema sem modificações. Queria dar uma motivação para usar mudanças propostas. Quero apresentar na sequência um exemplo usando o erro de rastreamento no cálculo do RAmSS. Ainda não estou com o resultado totalmente pronto. Decidi tentar colocar uma restrição para garantir um integrador mas os resultados não foram muito animadores. Mas acho que já percebi por que e creio que usando informação do erro de rastreamento isso pode melhorar.

Conclusões

6.1 Considerações finais

6.2 Propostas de continuidade

A principal foco desta pesquisa tem sido o estudo e desenvolvimento de metodologias de projeto de controladores DDC, com foco especial na seleção de estruturas do controlador com o uso da técnica VRFT.

Em particular, o método RaMSS, tem se mostrado promissor para a aplicação desejada. Esse método faz apelo às técnicas exploratórias que recorrem a buscas aleatórias ao estilo Monte Carlo, mas com mecanismos de seleção que reduzem drasticamente o custo computacional, evitando uma busca exaustiva, ao mesmo tempo em que tenta garantir uma seleção adequada de modelos. Apoiado nesta técnica, algumas adaptações têm sido estudadas no sentido de lidar com a identificação do controlador e não mais do processo.

Neste sentido, lida-se atualmente com questões que, apesar de estarem sendo abordadas no decorrer da pesquisa, resultados mais concretos ainda não foram alcançados. Porém, as experiências e estudos têm-se mostrado promissoras, no sentido que, do ponto de vista do autor, bons resultados podem ser alcançados. Na sequência apresentam-se itens específicos a serem abordados, que podem ser tomados como propostas de continuidade:

Uma primeira proposta diz respeito ao estudo do uso de índices de desempenho que melhor representem a realidade do controlador ao se atualizar os termos de RIPs. Como já abordado, originalmente o RaMSS utiliza medidas como o MSPE e MSSE para esta atualização. Para fins de modelagem de processos físicos, onde muitas vezes a predição do comportamento entrada-saída é o alvo, tais índices se mostram adequados [Falsone et al. \(2015\)](#). Porém, ao se abordar o problema da identificação do controlador, a redução do erro de predição, seja ele de passo a frente, como no caso do MSPE ou de simulação livre, como no caso do MSSE, nem sempre é o indicativo de que haverá erro de redução de rastreamento do modelo de referência. E, para sistemas de controle, é este erro de rastreamento se torna o principal alvo em sistemas de controle. Um estudo sobre o uso deste índice está em andamento. O que se tem observado é que minimizar o MSPE diretamente pela estratégia RaMSS apesar de muitas vezes apresentar bons resultados, não dá garantias que o rastreamento ótimo é alcançado, i.e. aquele em

conforme resultados apresentados na seção ???

não esquecer de explicar o porque destes resultados mesmo quando minimizando o MSPE, que no caso de con-

que o erro de rastreamento médio quadrático é mínimo.

Como alternativa, propõe-se o uso de algum índice que leve em conta o resultado em malha fechada ao se aplicar os controladores intermediários identificados e selecionados pelo procedimento. Algo parecido tem sido usado no que diz respeito a identificação de processos em que o erro quadrático médio de simulação (MSSE) é utilizado em substituição ao MSPE (Aguirre et al., 2010). Neste caso, segundo (Piroddi and Spinelli, 2003), o uso de informações da simulação-livre pode melhorar a robustez na seleção de estrutura do processo quando sob condições de identificabilidade parciais.

O MSSE depende da simulação livre, que em suma é a resposta em malha aberta a um sinal de excitação conhecido. Algo parecido poderia ser utilizado ao se avaliar a estrutura no procedimento VRFT, porém, neste caso, seria desejável a resposta do sistema em malha fechada com o controlador obtido a partir da estrutura avaliada. O grande problema neste caso é que esta simulação passa a ser dependente de um modelo, ainda que aproximado, do processo, ou do próprio processo. Porém, como estratégias DDC visam exatamente não identificar um modelo para o processo, tal situação pode ser um empecilho prático. Uma proposta de solução para este problema é apresentada ao final.

Uma segunda proposta, a qual também vem sendo analisada, consiste no uso de informações auxiliares durante o processo de identificação dos parâmetros do controlador. Apesar de já terem sido desenvolvidas técnicas para incorporar informação auxiliar no processo de identificação, por exemplo via restrições e otimização multi-objetivo (Barroso, 2006), todas estas restrições dizem respeito à planta. Neste sentido surgem questões como: de que forma estas técnicas podem ser usadas na abordagem DDC? Seria possível encontrar um análogo da informação auxiliar, usada em métodos tradicionais, para estratégias DDC, em que não há informação da planta? Poderia esta ser definida, por exemplo, a partir restrições que garantam aspectos relevantes ao controle, como limitações de ganho devido a saturação de atuadores, inserção de integradores no controlador, além de aspectos relativos a robustez? Neste sentido, um procedimento para garantir a presença de integradores no modelo do controlador já vem sendo estudado, mas ainda sem resultados conclusivos.

Outra proposta a ser estudada diz respeito ao estudo do uso de filtros no processo de identificação do controlador, como é comum na estratégia VRFT. Na estratégia, quando o controlador ideal, ou compatível, não pertence à classe de controladores considerada, ou seja, a hipótese 3.2 não é satisfeita, um filtro a ser aplicado ao sinal usado no processo de identificação deve ser projetado a fim de se aproximar de uma solução ótima, conforme apresentado por Campi and Weyer (2002); Campi and Savaresi (2006a) e discutido no Capítulo 3.

Uma quarta proposta diz respeito ao problema levantado anteriormente, onde o sinal de saída, e conseqüentemente o erro de rastreamento são requeridos para o cálculo do índice de atualização dos RIPs no procedimento RaMSS. Como a simulação da resposta em malha fechada (ou mesmo malha aberta) é inviável em estratégia DDC,

terminar este pensamento

devido a uma falta de modelo para o processo, pretende-se fazer um estudo do uso de técnicas de Aprendizado por Reforço (RL), abordadas no Capítulo 4, para que dados colhidos do processo real, enquanto em funcionamento, possam ser usados para o cálculo em tempo real dos RIP e consequentemente para escolha de melhor estrutura.

Algumas técnicas de RL se mostram promissoras neste caso, uma vez que muitas vezes levam à otimização de índices de desempenho a partir de dados amostrados, sem a necessidade do modelo do processo, ao mesmo tempo em que evitam o alto número de realizações amostrais como em metodologias Monte Carlo. Dentre elas a estratégia TD Learning, tem sido considerada, com uma atenção ao método conhecido como Q-learning [Watkins and Dayan \(1992\)](#), que permite que um controlador possa ser ajustado em uma abordagem conhecida como *off-policy* que permite o aprendizado de uma política de controle enquanto o sistema em malha fechada se encontra sob o efeito de outra. No âmbito deste trabalho, o sentimento é que deva ser possível o uso de uma estratégia parecida juntamente com o concito do RAmSS, possa se atualizar os RIPs e consequentemente a estrutura, e talvez até parâmetros, do controlador com um menor esforço e, se possível, com provas de convergência.

Colocar referência

Por fim, análises a respeito de robustez, na presença de ruídos de medição ou de processos devem ser também levadas em conta, principalmente em uma etapa final. Inclusão de termos de média móvel ao procedimento RaMSS tem sido cogitado como alternativa a reduzir a polarização durante a etapa de identificação, em alternativa ao uso de estratégias baseadas em variáveis instrumentais, comuns no procedimento VRFT.

Bibliography

- Aguirre, L. A. (2015). *Introdução à Identificação de Sistemas: Técnicas Lineares e Não Lineares: Teoria e Aplicação*. Belo Horizonte, fourth edition.
- Aguirre, L. A., Barbosa, B. H. G., and Braga, A. P. (2010). Prediction and simulation errors in parameter estimation for nonlinear systems. *Mechanical Systems and Signal Processing*, 24(8):2855–2867.
- Aguirre, L. A. and Billings, S. (1995). Dynamical effects of overparametrization in nonlinear models. *Physica D: Nonlinear Phenomena*, 80(1-2):26–40.
- Aguirre, L. A., Donoso-Garcia, P. F., and Santos-Filho, R. (2000). Use of a priori information in the identification of global nonlinear models-a case study using a buck converter. *IEEE Transactions on Circuits and Systems I: Fundamental Theory and Applications*, 47(7):1081–1085.
- Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6):716–723.
- Allen, D. M. (1974). The Relationship between Variable Selection and Data Agumentation and a Method for Prediction. *Technometrics*, 16(1):125–127.
- Alves, M. A., Corrêa, M. V., and Aguirre, L. A. (2012). Use of self-consistency in the structure selection of NARX polynomial models. *International Journal of Modelling, Identification and Control*, 15(1):1.
- Barroso, M. F. S. (2006). *Otimização Bi-Objetivo Apliada à Estimação de Parâmetros de Modelos Não-Lineares: Caraterização e Tomada de Decisão*. PhD thesis, UFMG.
- Bazanella, A. S., Gevers, M., Mišković, L., and Anderson, B. D. (2008). Iterative minimization of H_2 control performance criteria. *Automatica*, 44(10):2549–2559.
- Billings, S. (1980). Identification of nonlinear systems—a survey. *IEE Proceedings D Control Theory and Applications*, 127(6):272.

- Billings, S. A., Chen, S., and Korenberg, M. J. (1989). Identification of MIMO nonlinear systems using a forward-regression orthogonal estimator. *International Journal of Control*, 49(6):2157–2189.
- Broomhead, D. S. and Lowe, D. (1988). Radial basis functions, multi-variable functional interpolation and adaptive networks. Technical report, Royal Signals and Radar Establishment Malvern (United Kingdom).
- Campi, M., Lecchini, A., and Savaresi, S. (2002). Virtual reference feedback tuning: A direct method for the design of feedback controllers. *Automatica*, 38(8):1337–1346.
- Campi, M. C. and Savaresi, S. M. (2006a). Direct nonlinear control design: The virtual reference feedback tuning (VRFT) approach. *IEEE Transactions on Automatic Control*, 51(1):14–27.
- Campi, M. C. and Weyer, E. (2002). Finite sample properties of system identification methods. *IEEE Transactions on Automatic Control*, 47(8):1329–1334.
- Campi, M. M. C. and Savaresi, S. S. M. (2006b). Direct nonlinear control design: The virtual reference feedback tuning (VRFT) approach. *IEEE Transactions on Automatic Control*, 51(1):14–27.
- Cavanaugh, J. E. (1997). Unifying the derivations for the Akaike and corrected Akaike information criteria. *Statistics & Probability Letters*, 33(2):201–208.
- Chen, S. and Billings, S. A. (1992). Neural networks for nonlinear dynamic system modelling and identification. *International Journal of Control*, 56(2):319–346.
- Chen, S., Billings, S. A., Cowan, C. F. N., and Grant, P. M. (1990). Practical identification of NARMAX models using radial basis functions. *International Journal of Control*, 52(6):1327–1350.
- Falsone, A., Piroddi, L., and Prandini, M. (2014). A novel randomized approach to nonlinear system identification. In *53rd IEEE Conference on Decision and Control*, pages 6516–6521.
- Falsone, A., Piroddi, L., and Prandini, M. (2015). A randomized algorithm for nonlinear model structure selection. *Automatica*, 60:227–238.
- Guardabassi, G. O. and Savaresi, S. M. (2000). Virtual reference direct design method: An off-line approach to data-based control system design. *IEEE Transactions on Automatic Control*, 45(5):954–959.
- Haykin, S. S. (1994). *Neural Networks: A Comprehensive Foundation*. Macmillan ; Maxwell Macmillan Canada ; Maxwell Macmillan International, New York : Toronto : New York.

- Hjalmarsson, H., Gunnarsson, S., and Gevers, M. (1994). A convergent iterative restricted complexity control design scheme. *Proceedings of 1994 33rd IEEE Conference on Decision and Control*, 2(December):1735–1740.
- Hou, Z. S. and Wang, Z. (2013). From model-based control to data-driven control: Survey, classification and perspective. *Information Sciences*, 235:3–35.
- Huang, B. and Kadali, R. (2008). Dynamic modeling, predictive control and performance monitoring. In *Lecture Notes in Control and Information Sciences*, page 249.
- Huusom, J. K., Poulsen, N. K., and Jørgensen, S. B. (2009). Improving convergence of iterative feedback tuning. *Journal of Process Control*, 19(4):570–578.
- Ikeda, M., Fujisaki, Y., and Hayashi, N. (2001). A model-less algorithm for tracking control based on input-output data. In *Nonlinear Analysis, Theory, Methods and Applications*, volume 47, pages 1953–1960.
- Jeng, J.-C. and Lin, Y.-W. (2014). Controller design for nonlinear hammerstein and wiener systems based on VRFT method. In *Computer Aided Chemical Engineering*, volume 33, pages 547–552.
- Jeng, J.-C. and Lin, Y.-W. (2018). Data-driven nonlinear control design using virtual-reference feedback tuning based on the block-oriented modeling of nonlinear systems. *Industrial & Engineering Chemistry Research*, 57(22):7583–7599.
- Kammer, L., Bitmead, R., and Bartlett, P. (2000). Direct iterative tuning via spectral analysis. In *Proceedings of the 37th IEEE Conference on Decision and Control (Cat. No.98CH36171)*, volume 3, pages 2874–2879. IEEE.
- Karimi, A., Mišković, L., and Bonvin, D. (2002). Convergence analysis of an iterative correlation-based controller tuning method. *IFAC Proceedings Volumes (IFAC-PapersOnline)*, 35(1):413–418.
- Karimi, A., van Heusden, K., and Bonvin, D. (2007). Non-iterative data-driven controller tuning using the correlation approach. In *2007 European Control Conference (ECC)*, volume 3536, pages 5189–5195. IEEE.
- Kashyap, R. (1977). A Bayesian comparison of different classes of dynamic models using empirical data. *IEEE Transactions on Automatic Control*, 22(5):715–727.
- Korenberg, M., Billings, S. A., Liu, Y. P., and McILROY, P. J. (1988). Orthogonal parameter estimation algorithm for non-linear stochastic systems. *International Journal of Control*, 48(1):193–210.
- Leontaritis, I. J. and Billings, S. A. (1985a). Input-output parametric models for non-linear systems Part I: Deterministic non-linear systems. *International Journal of Control*, 41(2):303–328.

- Leontaritis, I. J. and Billings, S. A. (1985b). Input-output parametric models for non-linear systems Part II: Stochastic non-linear systems. *International Journal of Control*, 41(2):329–344.
- Ljung, L. (1999). *System Identification: Theory for the User*. Prentice Hall, New Jersey, US.
- Martins, S. A. M., Nepomuceno, E. G., and Barroso, M. F. S. (2013). Improved Structure Detection For Polynomial NARX Models Using a Multiobjective Error Reduction Ratio. *Journal of Control, Automation and Electrical Systems*, 24(6):764–772.
- Pearson, R. K. (1999). *Discrete-Time Dynamic Models*. Topics in Chemical Engineering. Oxford University Press, New York.
- Piroddi, L. and Spinelli, W. (2003). An identification algorithm for polynomial NARX models based on simulation error minimization. *International Journal of Control*, 76(17):1767–1781.
- Retes, P. F. L. and Aguirre, L. A. (2019). NARMAX model identification using a randomised approach. *International Journal of Modelling, Identification and Control*, 31(3):205.
- Safonov, M. G. and Tsao, T.-C. (1995). The unfalsified control concept: A direct path from experiment to controller. *Feedback Control, Nonlinear Systems, and Complexity*, pages 196–214.
- Schaal, S. and Atkeson, C. G. (1994). Robot juggling: Implementation of memory-based learning. *IEEE Control Systems*, 14(1):57–71.
- Schwarz, G. (1978). Estimating the Dimension of a Model. *The Annals of Statistics*, 6(2):461–464.
- Shi, G. and Skelton, R. E. (2000). Markov data-based LQG control. *Journal of Dynamic Systems, Measurement, and Control*, 122(3):551.
- Spall, J. (1992). Multivariate stochastic approximation using a simultaneous perturbation gradient approximation. *IEEE Transactions on Automatic Control*, 37(3):332–341.
- Strang, G. (1989). Wavelets and Dilation Equations: A Brief Introduction. *SIAM Review*, 31(4):614–627.
- Takahashi, Y., Rabins, M. J., and Auslander, D. M. (1972). *Control and Dynamic Systems*. Addison-Wesley, California.
- Tolle, M. (1921). *Regelung Der Kraftmaschinen*. Springer, Berlin.
- Watkins, C. J. C. H. and Dayan, P. (1992). Q-learning. *Machine Learning*, 8(3-4):279–292.

Web of Science (2018). Web of science.

Zhu, Q. (2005). An implicit least squares algorithm for nonlinear rational model parameter estimation. *Applied Mathematical Modelling*, 29(7):673–689.

Ziegler, J. G. and Nichols, N. B. (1942). Optimum settings for automatic controllers. *Transactions of ASME*, 64:759–768.